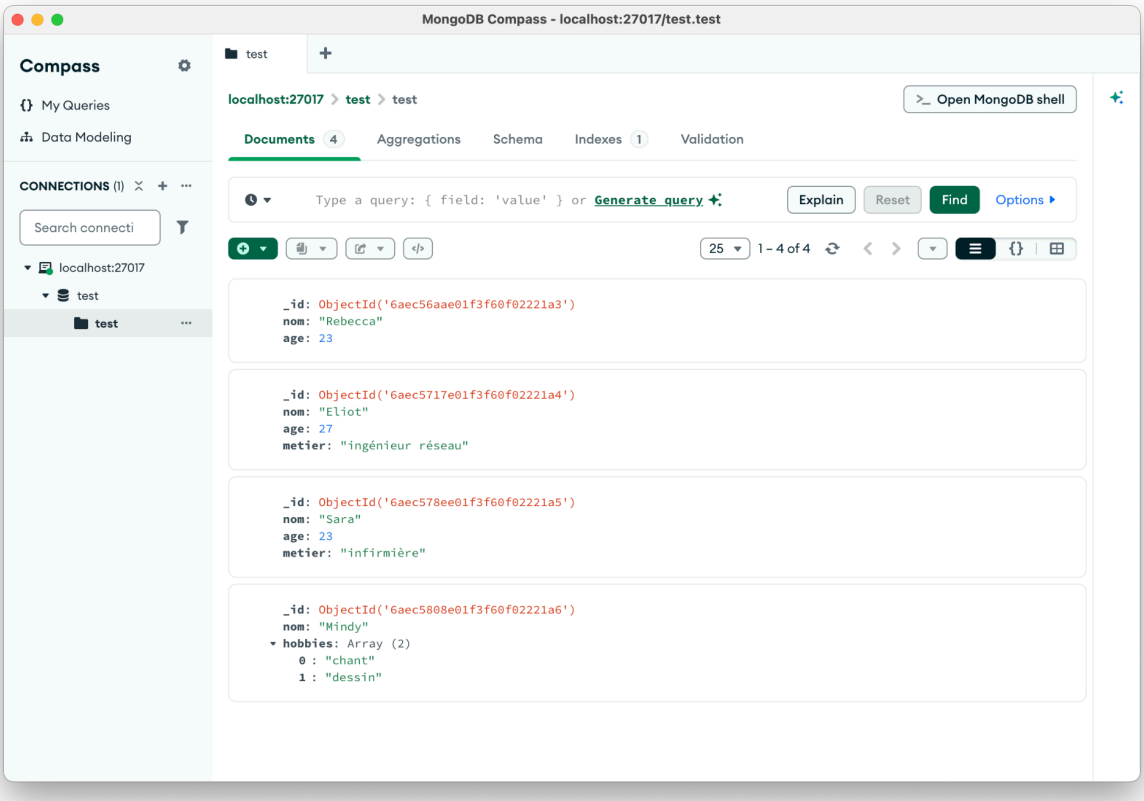
Plateformes pour les big data
CSC 5066

TP2 - MongoDB

OBJECTIFS

Ce TP porte sur la migration d'une base médicale relationnelle (SQLite) vers une base orientée document (MongoDB). L'enjeu est d'appréhender la dénormalisation en regroupant les données dans deux collections (médicaments et patients) afin d'optimiser les lectures. Le travail se déroule en 3 axes: le développement d'un script ETL en Python pour restructurer et exporter les données en JSON, l'analyse des performances de requêtes (filtrage et agrégations) et l'automatisation des opérations CRUD via pymongo

ETAPE 1 : CRÉATION D'UNE PREMIÈRE BASE ET D'UNE COLLECTION



ETAPE 2 : TRAVAILLER SUR LA BASE DES MÉDICAMENTS

5 à 10 requêtes cibles pour l'optimisation du schéma NoSQL

1. Afficher tous les détails d'un médicament (nom, forme, autorisations, groupe génériques, substances et conditionnements de boîtes)
2. Afficher la fiche d'un patient et tout son historique d'ordonnances
3. Afficher tous les médicaments contenant une substance active donnée
4. Afficher tous les patients d'une certaine tranche d'âge et d'un genre particulier
5. Afficher tous les médicaments d'une forme pharmaceutique spécifique
6. Afficher tous les médicaments d'un groupe générique précis
7. Recherche des patients sous traitement de longue durée

Schéma NoSQL équivalent au schéma relationnel

Plutôt que d'avoir 7 tables Séparé avec de nombreuses clés étrangères, on regroupe les données par centre d'intérêt métier via l'imbrication :

- Collection médicaments: chaque document contient le médicament, son groupe générique directement imbriqué, la liste de ses présentations et la liste de ses substances chimiques sous forme de tableaux imbriqués
- Collection patients: Chaque document contient les données du patient, ainsi que le tableau de toutes ses prescriptions

Comparaison des modélisations relationnelles et NoSQL (avantages et inconvénients)

Avantages du modèle NoSQL:

- Aucune jointure SQL nécessaire pour afficher tous les informations d'un médicament ou d'un patient, on peut les obtenir par simple lecture de document
- Schéma flexible contre de fortes et strictes contraintes d'intégrité pour les modélisation relationnelles

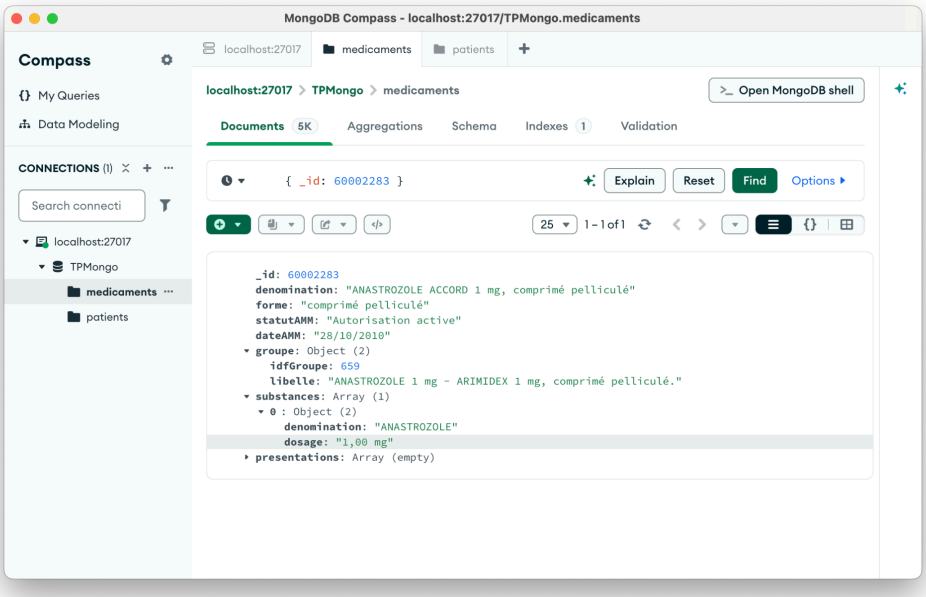
Inconvénients du Modèle NoSQL:

- Si le libellé d'un groupe générique change, il faut mettre à jour tous les médicaments appartenant à ce groupe (au lieu d'une seule ligne dans la table Groupes en SQL
- Un patient avec beaucoup de prescriptions fait grossir son document individuel
- Redondance des données dû à une dénormalisation assumée (par ex libellés de groupes dupliqués)

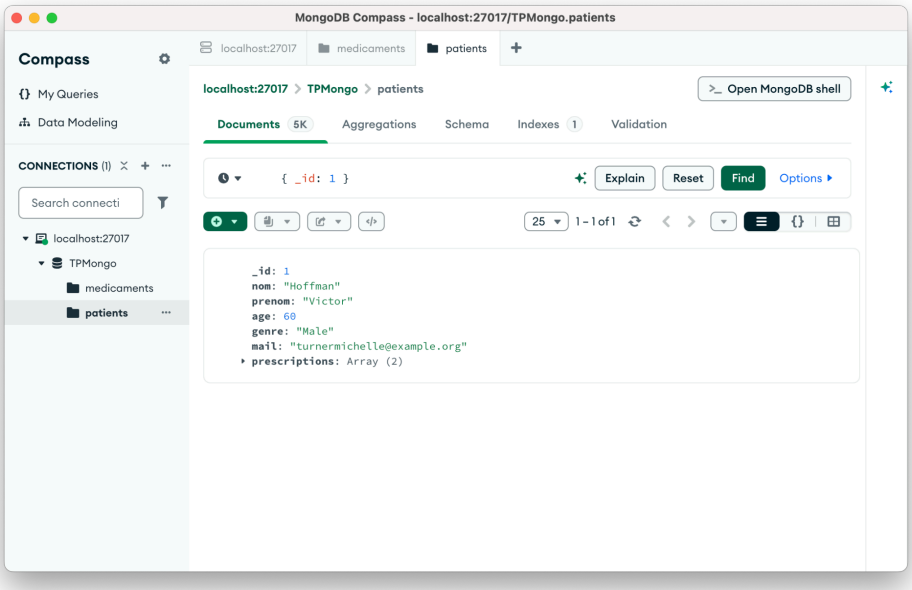
5 requêtes de filtrage simples sur les collections chargées (dont 1 non optimale au modèle NoSQL)

J'ai repris les 4 premières requêtes de cibles et ajouter une 5ème non optimale

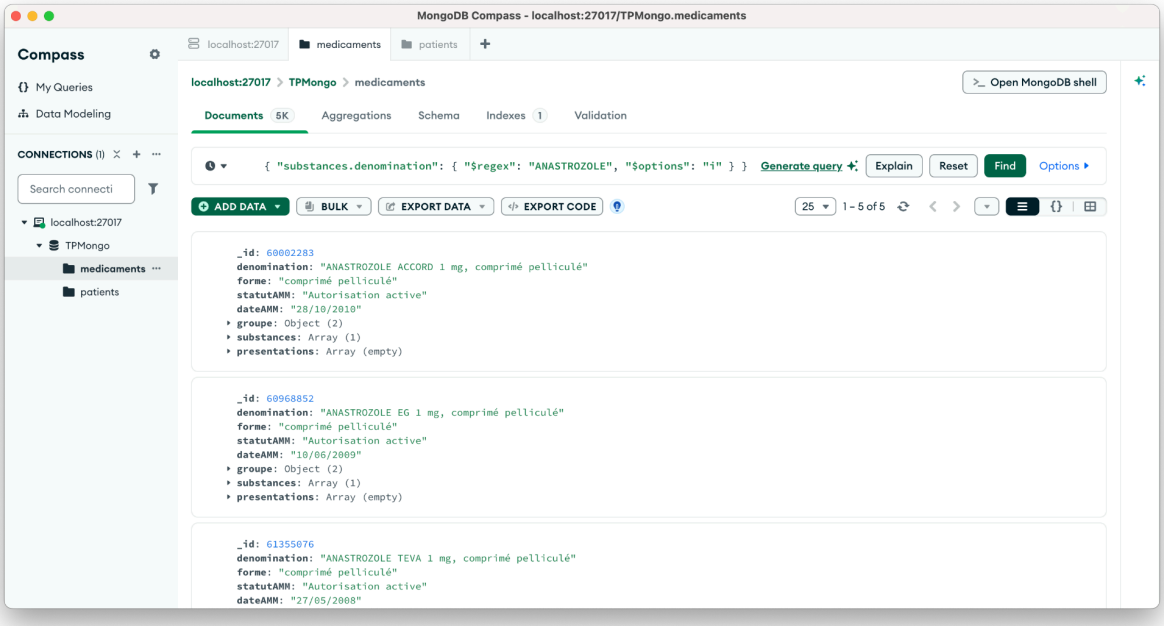
1. Afficher tous les détails d'un médicament (le médicament avec l'id = 60002283)



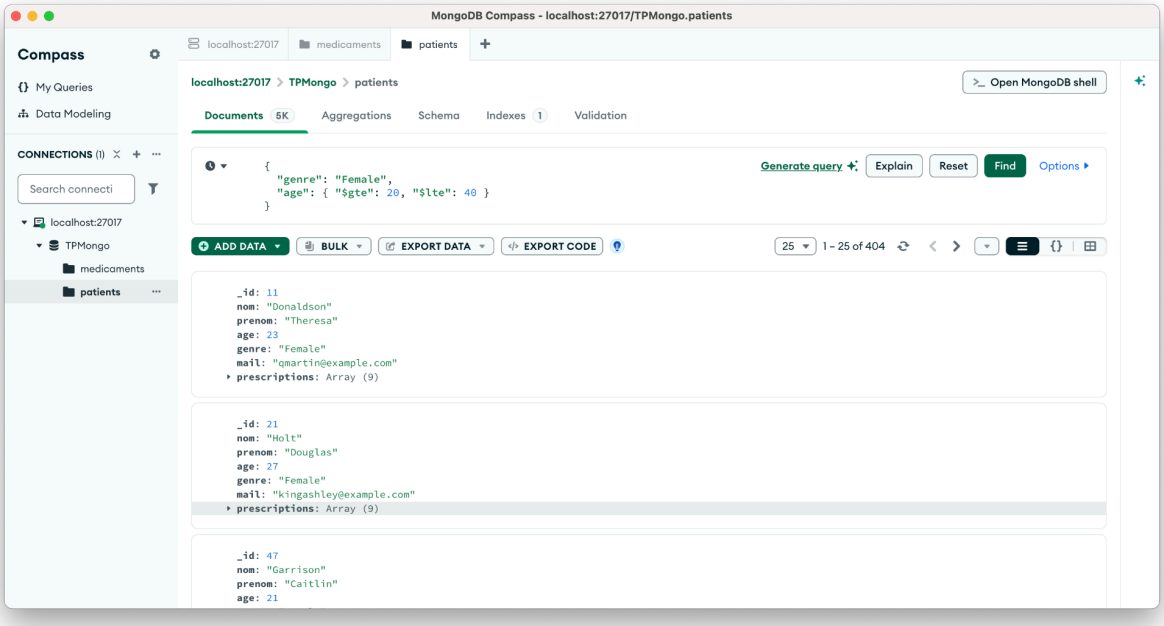
2. Afficher la fiche d'un patient et tout son historique d'ordonnances (le patient avec l'id = 1)



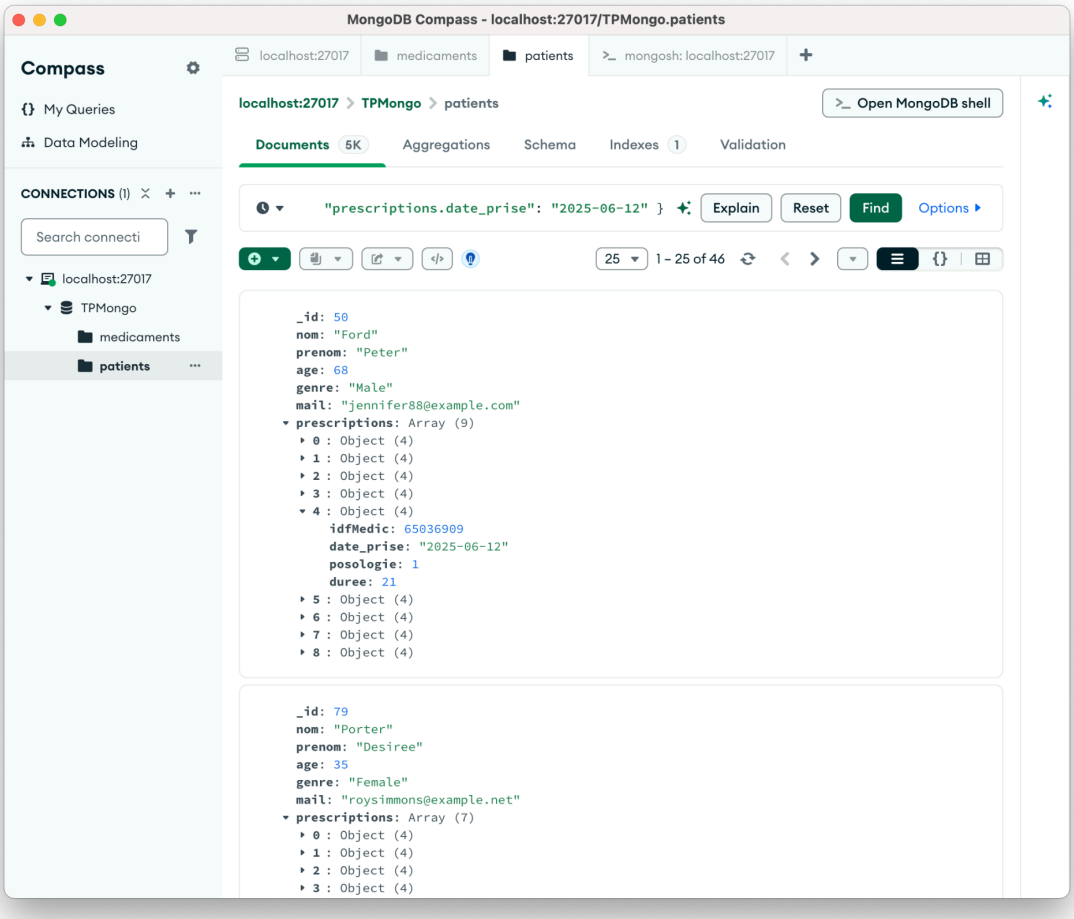
3. Afficher tous les médicaments contenant une substance active donnée (ANASTROZOLE)



4. Afficher tous les patients d'une certaine tranche d'âge et d'un genre particulier (entre 20 et 40 ans)



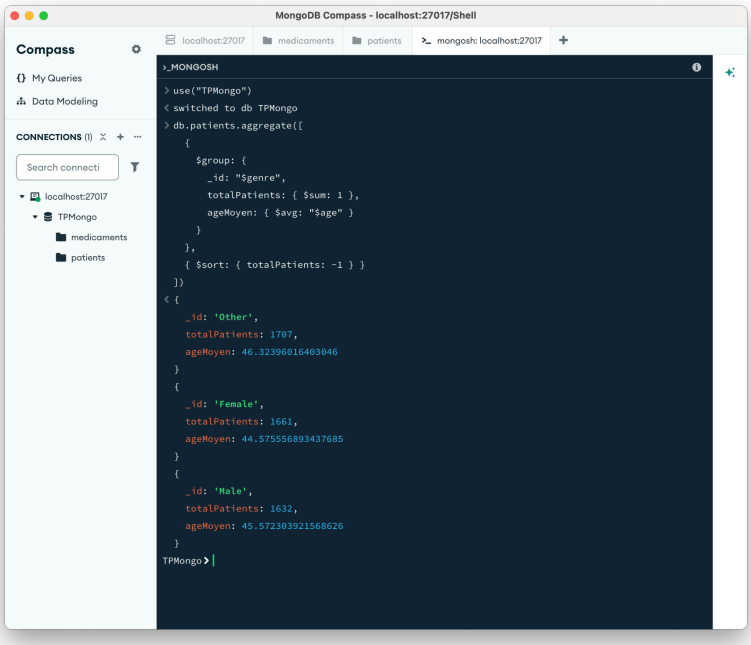
5. Afficher un médicament à partir du code d'une de ses boîtes



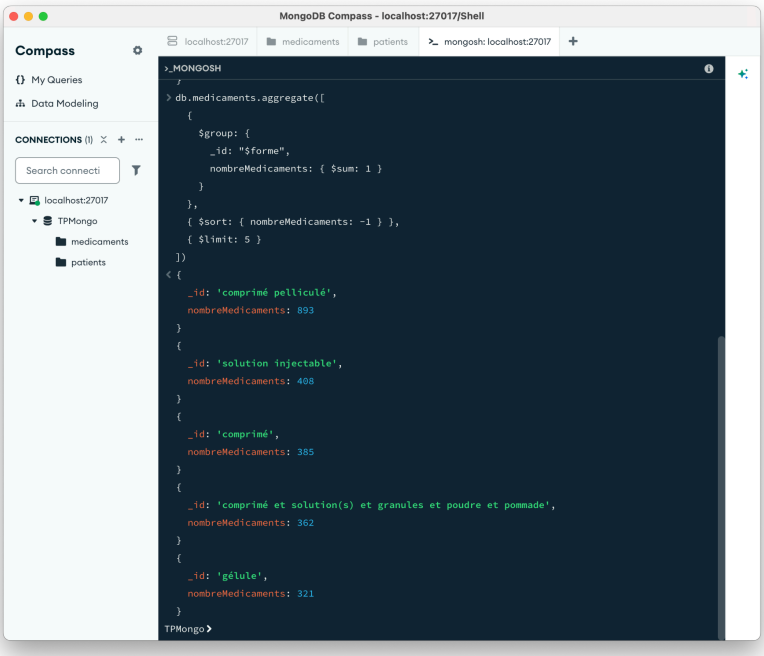
Cette requête n'est pas optimale car le critère de recherche est enfoui dans la liste des prescriptions de chaque patient. MongoDB doit donc ouvrir chaque dossier patient un à un et parcourir tout son historique médical ce qui consomme du temps et de la mémoire

5 requêtes d'agrégations sur les collections chargées (dont 1 non optimale au modèle NoSQL)

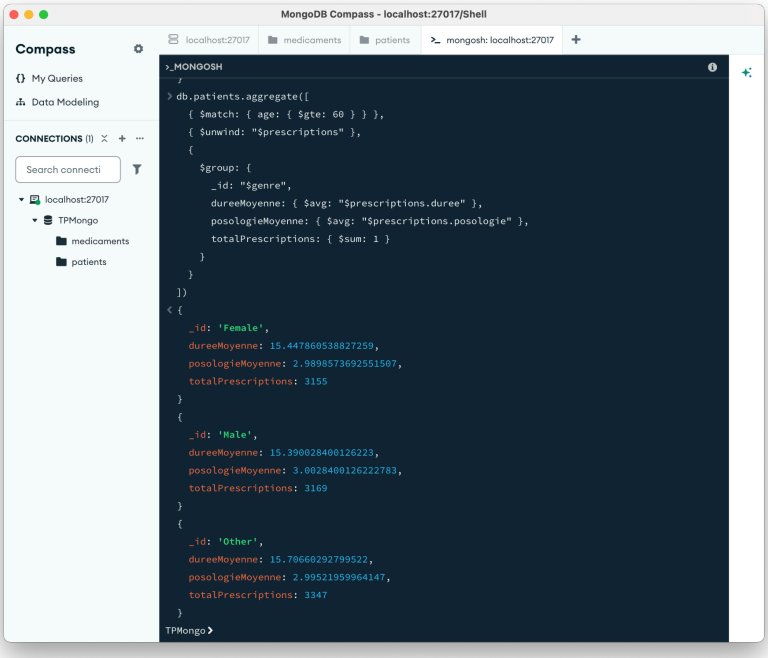
1. Afficher la répartition et âge moyen des patients par genre



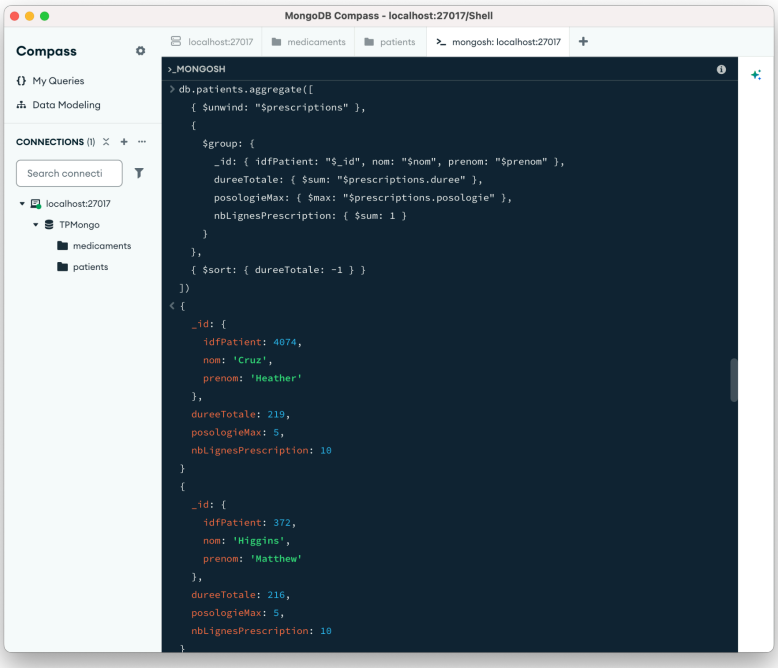
2. Afficher le Top 5 des formes pharmaceutiques les plus représentées



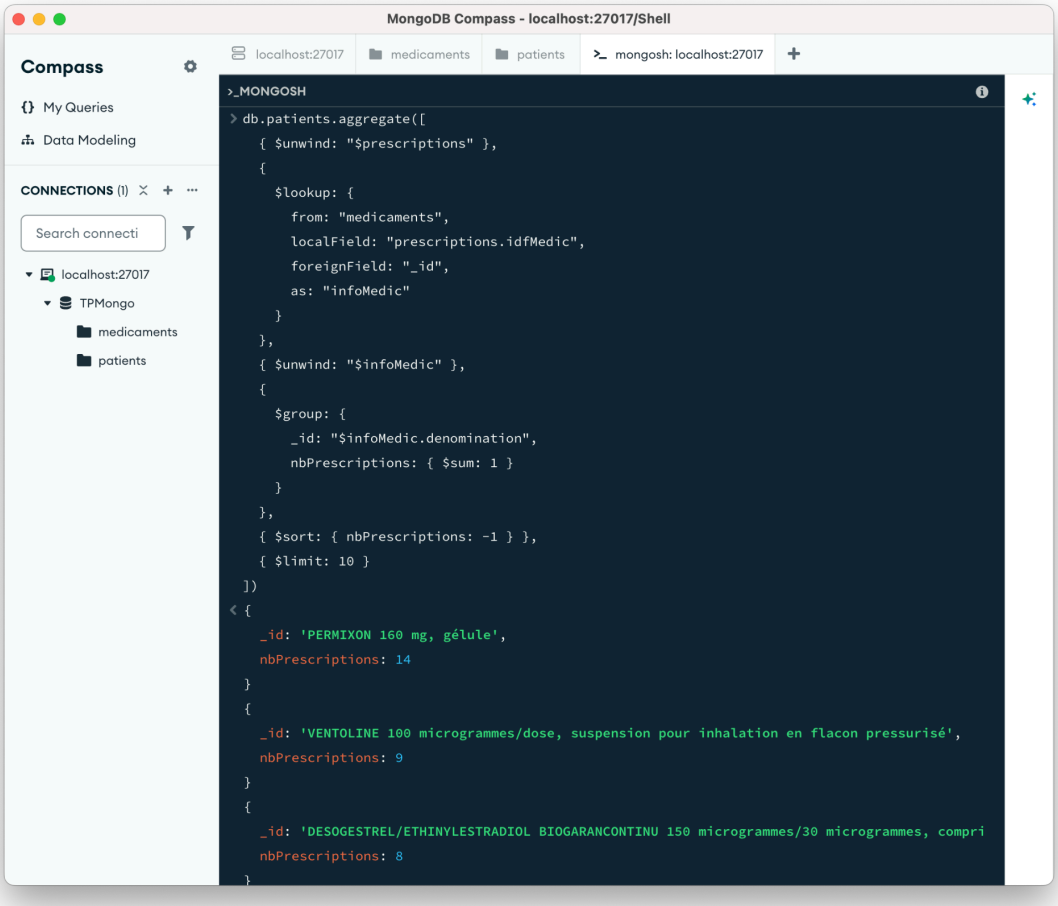
3. Afficher la posologie et durée moyennes des prescriptions pour les patients de +60 ans par genre



4. Afficher la durée cumulée des traitements de chaque patient et la posologie la plus forte reçue



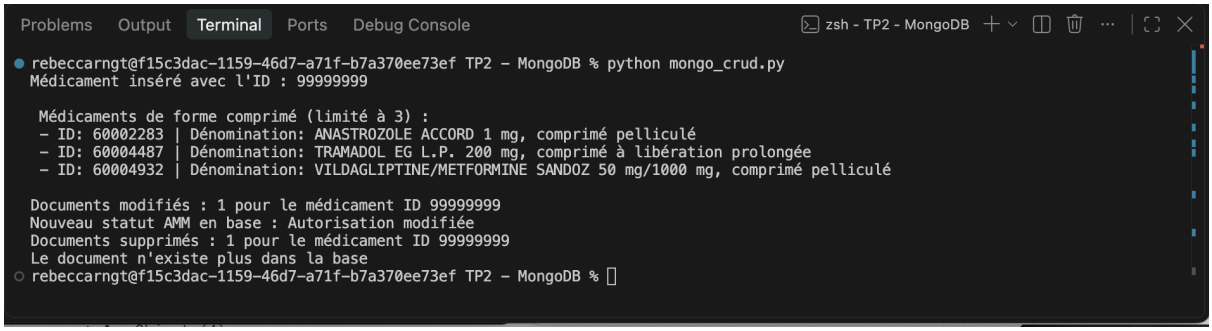
5. Afficher le nombre de de fois où chaque médicament a été prescrit



Cette requête force MongoDB à faire une jointure entre deux grosses collections avec $lookup ce qui est très lent et prend beaucoup de mémoire. Le but du NoSQL est justement d'éviter ces liaisons. Pour aller vite, il aurait fallu mettre directement le nom du médicament dans l'ordonnance du patient dès le départ

ÉTAPE 3 : PYMONGO

Sortie console du Script Python autonome qui interagit avec ma base MobgoDB


Problems
Output
Terminal
Ports
Debug Console
zsh - TP2 - MongoDB
rebeccarngt@f15c3dac-1159-46d7-a71f-b7a370ee73ef TP2 - MongoDB % python mongo_crud.py
Médicament inséré avec l'ID : 99999999
Médicaments de forme comprimé (limité à 3) :
- ID: 60002283 | Dénomination: ANASTROZOLE ACCORD 1 mg, comprimé pelliculé
- ID: 60004487 | Dénomination: TRAMADOL EG L.P. 200 mg, comprimé à libération prolongée
- ID: 60004932 | Dénomination: VILDAGLIPTINE/METFORMINE SANDOZ 50 mg/1000 mg, comprimé pelliculé
Documents modifiés : 1 pour le médicament ID 99999999
Nouveau statut AMM en base : Autorisation modifiée
Documents supprimés : 1 pour le médicament ID 99999999
Le document n'existe plus dans la base
rebeccarngt@f15c3dac-1159-46d7-a71f-b7a370ee73ef TP2 - MongoDB %