TP manipulation de données

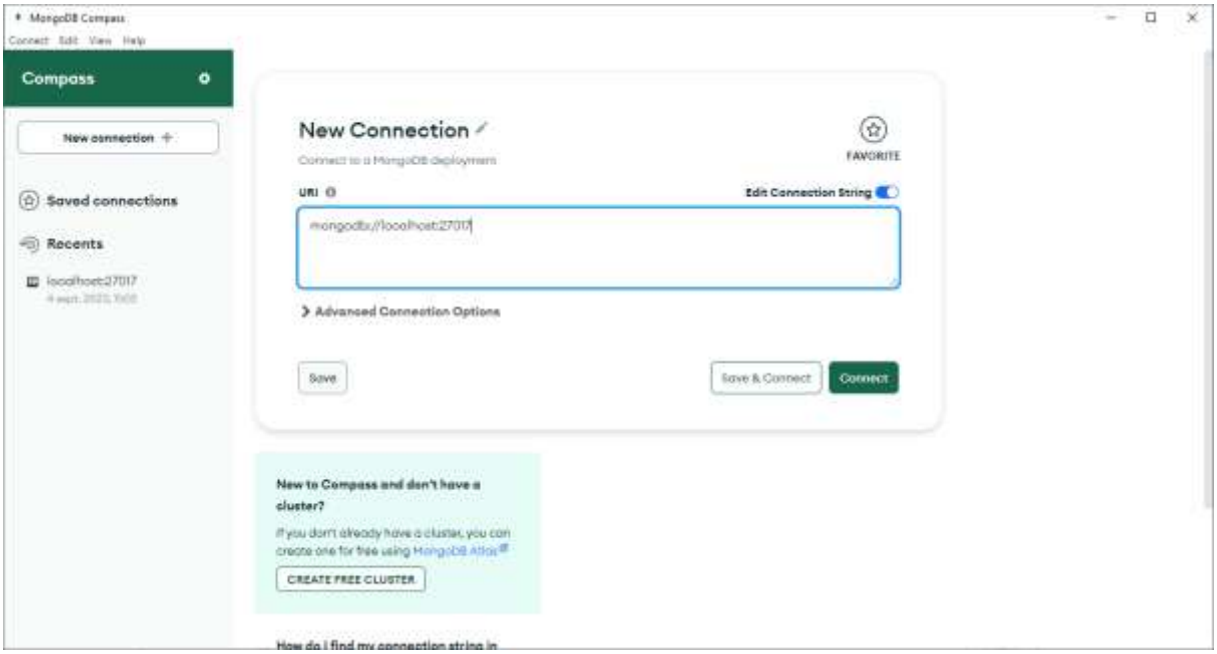
Le but de ce TP est de se familiariser avec un système de stockage de type NoSQL, en l'occurrence MongoDB. MongoDB est un système orienté document, c'est-à-dire qu'il gère des collections de documents, un document étant décrit par une structure JSON (composition via ensemble et tableau).

Préalable : installation de MongoDB

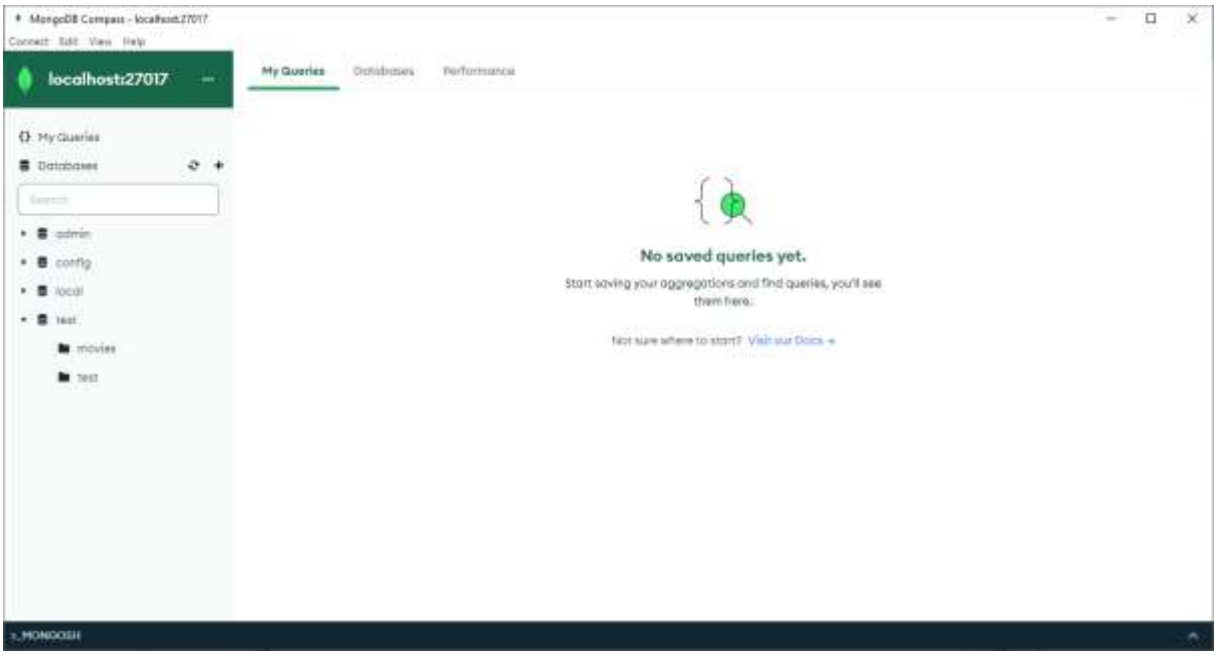
Aller sur https://www.mongodb.com/try/download/community et choisir la plateforme correspondant à votre machine (installer également compass qui est un outil graphique pour MongoDB permettant de simplifier l'interaction avec celui-ci)

Première étape : création d'une première base et d'une collection

Si MongoDB n'est pas lancé automatiquement au démarrage de votre machine il faut le lancer. Ensuite on lance compass sur lequel on va commencer par se connecter :

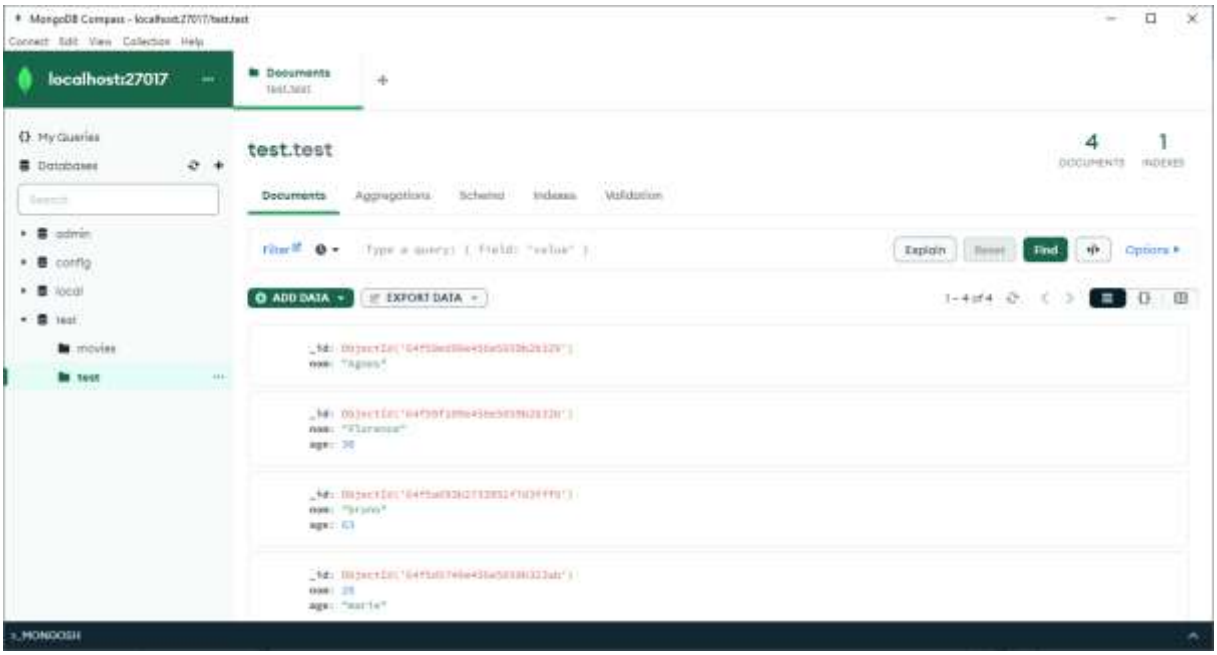


On va ensuite créer une première base de données (il suffit de lui donner un nom par exemple test, en sélectionnant le bouton + à côté de databases (frame de gauche) :



Une fois sur test, on voit les collections existantes (s'il y en a déjà) et on peut en créer de nouvelles (par exemple une de nom test).

Une fois sur la collection test, on voit les documents existants (s'il y en a), on peut en ajouter soit un par un, soit en chargeant un fichier csv ou json et on peut également exporter la collection ou filtrer la collection :



Vous pouvez maintenant ajouter un document (par exemple une personne en prenant vous-même comme exemple avec votre nom, prénom, âge, vos hobbys, vos sports préférés, …).

Ajouter d'autres personnes sans respecter le même schéma que votre premier ajout (par exemple ne remplissez pas un attribut, ajoutez en un autre, changer le type d'un attribut).

Une fois les personnes ajoutées vous pouvez maintenant tester les différentes opérations comme mise à jour, suppression et surtout filtrage (la vision tabulaire de la collection vous permet d'avoir

une interface proche de phpmyadmin qui vous permet de réaliser les différentes opérations de manière graphique). Vous pouvez également ouvrir une fenêtre de mongosh (shell mongoDB) qui vous permet de faire les opérations en utilisant l'API MongoDB.

Deuxième étape : travailler sur la base des médicaments

On va reprendre la base relationnelle utilisée lors du TP manipulation de données et la gérer sous forme NoSQL.

- choisir 5 à 10 requêtes représentatives des accès que vous souhaitez les plus efficaces possibles et proposer un schéma NoSQL équivalent au schéma relationnel (capable de stocker la même information) et efficace pour les requêtes choisies. Comparer les modélisations relationnelles et NoSQL (avantages et inconvénients). Par exemple regarder qu'est ce qui est le plus simple, le plus redondant, les modes d'accès aux données qui sont privilégiés ou non

- Construire un programme python qui exporte les données sous forme relationnelle en json en respectant le schéma NoSQL du dessus (un fichier par collection, vous pouvez ne garder qu'un sous ensemble des données)

- Importer les fichiers json générés dans mongodb

- Ecrire 5 requêtes de filtrage simples sur les collections chargées dont au moins une qui n'est pas « optimale » relativement au schéma NoSQL choisi

- Ecrire 5 requêtes d'agrégations dont au moins une qui n'est pas « optimale » relativement au schéma NoSQL choisi

(regarder http://docs.mongodb.org/manual/reference/operator/query/all/ , http://docs.mongodb.org/manual/core/aggregation-pipeline et http://docs.mongodb.org/manual/reference/operator/aggregation-pipeline)

Troisième étape : pymongo

Ecrire un programme python accédant à la BD MongoDB et effectuant les opérations CRUD (par exemple ajouter un médicament, modifier le, supprimer le et écrire une des requêtes simples de la partie précédente).